FUNDAÇÃO ESCOLA DE COMÉRCIO ÁLVARES PENTEADO
FECAP

CENTRO UNIVERSITÁRIO ÁLVARES PENTEADO

ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

ALEXANDRA CHRISTINE SILVA RAIMUNDO – 24026156
CARLOS AUGUSTO SANTOS DE ALMEIDA - 20010535
HEBERT DOS REIS ESTEVES - 24026079
JOSÉ BENTO ALMEIDA GAMA - 24026127

Cannoli Intelligence – Inteligência Artificial e Machine Learning

São Paulo
2025

Sumário

1.0 Introdução

Este documento corresponde à etapa de aplicação de Inteligência Artificial (IA) no projeto Cannoli Intelligence. O objetivo é demonstrar como técnicas de IA e Machine Learning podem ser integradas ao sistema para enriquecer os dashboards, não apenas apresentando métricas, mas também oferecendo insights estratégicos e recomendações automáticas aos clientes.

2.0 Referencial Teórico

A aplicação de IA em sistemas de análise de dados pode ser dividida em três eixos principais:

- **Detecção de anomalias (IA Reativa)** → uso de algoritmos para identificar desvios inesperados, como quedas abruptas em campanhas.
- **Previsão (Machine Learning Supervisionado)** → regressão ou classificação para estimar resultados futuros, como número de cliques ou receita.
- **Recomendações heurísticas (Busca Gulosa)** → escolha da melhor opção em tempo real, baseada em métricas de eficiência.

Segundo Russell & Norvig (2010), sistemas inteligentes devem perceber padrões no ambiente e agir de acordo. Para o *Cannoli Intelligence*, isso significa transformar dados de campanhas em **alertas, previsões e sugestões de ação**.

3.0 Metodologia

A metodologia adotada para implementação de IA seguiu as seguintes etapas:

1. **Preparação dos Dados**
    - Seleção de variáveis relevantes (*custo, cliques, conversões, receita, status*).
    - Tratamento de valores ausentes e padronização de categorias (conforme explorado no documento de qualidade).
2. **Definição de Casos de Uso de IA**
    - **IA Reativa (alertas):** identificação de quedas abruptas em métricas de campanha.
    - **ML Preditivo:** regressão linear para prever desempenho futuro (ex.: cliques semanais).
    - **Busca Gulosa:** recomendação de campanhas mais eficientes com base em conversões por custo.
3. **Execução de Testes com Dados Simulados**
    - Dados fictícios foram utilizados para validar a lógica, garantindo que os algoritmos se comportam de forma esperada.
4. **Integração ao Dashboard**
    - Criação do card **“Sugestões IA”**, onde são exibidos os insights de forma interpretável pelos clientes.

4.0 Aplicações de IA

4.1 Alertas Inteligentes (IA Reativa)

- **Descrição:** monitoramento contínuo das métricas de campanha.
- **Exemplo:** se a taxa de cliques cair mais de 30% em relação à média da semana, o sistema gera alerta.
- **Benefício:** permite reação imediata do cliente, evitando perda de engajamento.

4.2 Previsão de Desempenho (ML Supervisionado)

- **Descrição:** uso de Regressão Linear para estimar valores futuros de cliques, conversões e faturamento.
- **Exemplo:** prever se uma campanha atingirá a meta até o fim do mês.
- **Benefício:** apoio estratégico no planejamento de campanhas e alocação de verba.

4.3 Recomendação por Busca Gulosa

- **Descrição:** seleção das campanhas mais promissoras com base em uma heurística simples (eficiência = conversões ÷ custo).
- **Exemplo:** ranquear campanhas e recomendar aumentar investimento nas 3 mais eficientes.
- **Benefício:** gera sugestões rápidas e compreensíveis, exibidas no card de IA do dashboard.

5.0 Resultado com Dados Simulados

Durante os testes iniciais:

- **Alertas:** quedas simuladas de engajamento foram corretamente detectadas e sinalizadas.
- **Previsões:** os modelos apresentaram erro médio abaixo de 15%, suficiente para cenários de apoio à decisão.
- **Busca Gulosa:** a recomendação priorizou campanhas que, na simulação, resultaram em maior número de conversões totais.

Esses resultados validam a viabilidade da aplicação prática da IA no projeto.

A integração de Inteligência Artificial ao *Cannoli Intelligence* reforça a proposta de transformar dashboards em ferramentas consultivas, já que as técnicas escolhidas são simples e eficientes, compatíveis com o estágio acadêmico e o tempo disponível para implementação. A principal limitação identificada está na qualidade dos dados, pois lacunas e inconsistências, documentadas no relatório anterior, podem comprometer a acurácia dos modelos. Assim, as próximas etapas devem concentrar-se no enriquecimento da base de clientes, na padronização das categorias de campanhas e no monitoramento contínuo da completude e consistência dos dados.

6.0 Implementação em Python

Para validar a aplicação prática das técnicas de **Inteligência Artificial e Machine Learning** no projeto *Cannoli Intelligence*, foi desenvolvido um código em Python com o objetivo de simular dados de campanhas, gerar alertas, realizar previsões e recomendar campanhas via busca gulosa.

```python
# Cannoli Intelligence - IA/ML
# - Geração de dados simulados de campanhas
# - IA Reativa: alertas de queda (média móvel e z-score)
# - ML Supervisionado: previsão de conversões (Regressão Linear)
# - Busca Gulosa: recomendação de alocação de orçamento

import os
import math
import json
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

from datetime import datetime, timedelta

# Importações de ML
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score

np.random.seed(42)

# Gerar dados simulados de campanhas

def simulate_campaigns(n_campaigns=6, days=90):
    base_date = datetime.today().date() - timedelta(days=days-1)
    rows = []
    for cid in range(1, n_campaigns+1):
        nome = f"Campanha_{cid}"
        # perfis diferentes por campanha
        base_impr = np.random.randint(8_000, 30_000)
        base_ctr = np.random.uniform(0.03, 0.12)    # cliques/impressoes
        base_cr  = np.random.uniform(0.03, 0.18)    # conversoes/cliques
        cpc      = np.random.uniform(0.4, 1.8)      # custo por clique (R$)
        ticket   = np.random.uniform(20, 65)        # ticket médio (R$)


        for d in range(days):
            day = base_date + timedelta(days=d)
            saz  = 1 + 0.2*np.sin(2*math.pi*(d/7.0))  # semanal
            impr = int(np.random.normal(base_impr*saz, base_impr*0.08))
            impr = max(impr, 1000)
            clicks = int(impr * max(0.005, np.random.normal(base_ctr, 0.01)))
            convs  = int(clicks * max(0.01, np.random.normal(base_cr, 0.02)))
            cost   = round(clicks * max(0.1, np.random.normal(cpc, 0.15)), 2)
            rev    = round(convs * max(5, np.random.normal(ticket, 5)), 2)

```

C: > Users > alexa > OneDrive > Área de Trabalho > cannolli.py > ...

```python
                rows.append({
                    "date": day,
                    "campanhaId": cid,
                    "nome": nome,
                    "impressoes": impr,
                    "cliques": clicks,
                    "conversoes": convs,
                    "custo": cost,
                    "receita": rev
                })

        # insere queda  em 2 dias
        for drop_day in np.random.choice(range(days//3, days-2), size=2, replace=False):
            idx = (cid-1)*days + drop_day
            rows[idx]["cliques"] = max(1, rows[idx]["cliques"] // 3)
            rows[idx]["conversoes"] = max(0, rows[idx]["conversoes"] // 3)
            rows[idx]["receita"] = round(rows[idx]["receita"] * 0.35, 2)

    df = pd.DataFrame(rows)
    return df

df = simulate_campaigns(n_campaigns=6, days=90)

# Salvar CSV
csv_path = "campanhas_simulado.csv"
df.to_csv(csv_path, index=False)

# IA Reativa – alertas de queda

def rolling_alerts(frame, janela=7, queda_perc=0.3, metodo="media"):
    """
    Gera alertas quando o valor do dia fica abaixo de (1 - queda_perc)*media_movel.
    metodo: 'media' ou 'zscore'
    """
    alerts = []
    for cid, grp in frame.sort_values("date").groupby("campanhaId"):
        g = grp.copy()
        g["media_7_cliques"] = g["cliques"].rolling(janela).mean()
        g["media_7_conv"] = g["conversoes"].rolling(janela).mean()
        g["z_cliques"] = (g["cliques"] - g["cliques"].rolling(janela).mean()) / (g["cliques"].rolling(janela).std()+1e-9)

        for i, row in g.iterrows():
            if pd.isna(row["media_7_cliques"]):
                continue
            motivo = None
            if metodo == "media":
                if row["cliques"] < (1-queda_perc) * row["media_7_cliques"]:
                    motivo = f"Cliques {row['cliques']} abaixo de {(1-queda_perc)*row['media_7_cliques']:.0f} (média 7d)"
```

C: > Users > alexa > OneDrive > Área de Trabalho > cannolli.py > ...

```
            else:
                if row["z_cliques"] < -2.0:
                    motivo = f"Z-score cliques = {row['z_cliques']:.2f} (< -2.0)"

            if motivo:
                alerts.append({
                    "date": row["date"],
                    "campanhaId": int(row["campanhaId"]),
                    "nome": row["nome"],
                    "motivo": motivo
                })
    return pd.DataFrame(alerts).sort_values(["date","campanhaId"])

alerts_df = rolling_alerts(df, janela=7, queda_perc=0.3, metodo="media")
alerts_path = "alertas_queda.csv"
alerts_df.to_csv(alerts_path, index=False)


ex_cid = df["campanhaId"].iloc[0]
serie = df[df.campanhaId==ex_cid].sort_values("date")
serie["mm7"] = serie["cliques"].rolling(7).mean()

plt.figure(figsize=(9,4))
plt.plot(serie["date"], serie["cliques"], label="Cliques")
plt.plot(serie["date"], serie["mm7"], label="Média móvel 7d")
drops = alerts_df[alerts_df.campanhaId==ex_cid]["date"]
plt.scatter(drops, serie[serie["date"].isin(drops)]["cliques"])
plt.title(f"Campanha {ex_cid} – cliques e média móvel")
plt.xlabel("Data"); plt.ylabel("Cliques"); plt.legend()
plot_alerts_path = "alertas.png"
plt.tight_layout(); plt.savefig(plot_alerts_path); plt.close()

# ML – previsão de conversões

# Features de ontem para prever conversões de hoje (por campanha)
df_sorted = df.sort_values(["campanhaId","date"]).copy()
df_sorted["cliques_lag1"] = df_sorted.groupby("campanhaId")["cliques"].shift(1)
df_sorted["impressoes_lag1"] = df_sorted.groupby("campanhaId")["impressoes"].shift(1)
df_sorted["custo_lag1"] = df_sorted.groupby("campanhaId")["custo"].shift(1)
df_sorted["receita_lag1"] = df_sorted.groupby("campanhaId")["receita"].shift(1)

model_df = df_sorted.dropna().copy()
X = model_df[["cliques_lag1","impressoes_lag1","custo_lag1","receita_lag1"]].values
y = model_df["conversoes"].values

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.25, shuffle=True, random_state=42)
reg = LinearRegression()
reg.fit(X_train, y_train)
```

C: > Users > alexa > OneDrive > Área de Trabalho > cannolli.py > ...

```python
reg.fit(X_train, y_train)
y_pred = reg.predict(X_test)

mae = mean_absolute_error(y_test, y_pred)
rmse = math.sqrt(mean_squared_error(y_test, y_pred))
r2 = r2_score(y_test, y_pred)

metrics = {"MAE": mae, "RMSE": rmse, "R2": r2}

# real vs previsto (amostra)
plt.figure(figsize=(6,6))
plt.scatter(y_test, y_pred, s=12)
plt.plot([y_test.min(), y_test.max()], [y_test.min(), y_test.max()])
plt.title("Previsão de conversões – Real vs Previsto")
plt.xlabel("Real"); plt.ylabel("Previsto")
plot_reg_path = "regressao.png"
plt.tight_layout(); plt.savefig(plot_reg_path); plt.close()

# Busca Gulosa – recomendação de orçamento

def greedy_recommend(df_ref, data_referencia=None, k=3, orcamento=1000.0, modo="eficiencia"):
    """
    Seleciona top-K campanhas por eficiência e aloca orçamento gulosamente.
    modo: 'eficiencia' (conversoes/custo) ou 'roi' (receita/custo)
    """
    if data_referencia is None:
        data_referencia = df_ref["date"].max()
    snap = df_ref[df_ref["date"]==data_referencia].copy()

    eps = 1e-6
    if modo=="roi":
        snap["score"] = snap["receita"] / (snap["custo"] + eps)
    else:
        snap["score"] = snap["conversoes"] / (snap["custo"] + eps)

    ranked = snap.sort_values("score", ascending=False).reset_index(drop=True)

    # Top-K recomendadas
    priorizar = ranked.head(k).copy()

    # Alocação gulosa de orçamento (até custo diário atual)
    restante = orcamento
    aloc = []
    for _, row in priorizar.iterrows():
        if restante <= 0: break
        sugerido = min(restante, max(100.0, row["custo"]*0.5))  # política simples
        aloc.append({
            "campanhaId": int(row["campanhaId"]),
```

C: > Users > alexa > OneDrive > Área de Trabalho > cannolli.py > ...

```
                "campanhaId": int(row["campanhaId"]),
                "nome": row["nome"],
                "score": float(row["score"]),
                "orcamentoSugerido": round(float(sugerido), 2)
            })
            restante -= sugerido

    # Ajustar/pausar: bottom-K
    ajustar = ranked.tail(min(k, len(ranked))).copy()
    ajustar = [{"campanhaId": int(r.campanhaId), "nome": r.nome, "motivo": "baixo score / alto custo"} for _, r in ajustar.iterrows()]

    return {
        "data_referencia": str(data_referencia),
        "heuristica": modo,
        "orcamento_total": orcamento,
        "priorizar": aloc,
        "ajustar_ou_pausar": ajustar
    }

recs = greedy_recommend(df, k=3, orcamento=1200.0, modo="eficiencia")
json_path = "sugestoes_gulosas.json"
with open(json_path, "w", encoding="utf-8") as f:
    json.dump(recs, f, ensure_ascii=False, indent=2)

# Salvar um relatório-resumo em texto

summary = f"""
Cannoli Intelligence — IA/ML (dados simulados)

1) Alertas (queda média móvel 7d, 30%):
- Total de alertas gerados: {len(alerts_df)}
- Exemplo primeira linha:
{alerts_df.head(1).to_string(index=False) if not alerts_df.empty else 'Sem alertas'}

2) Regressão Linear — previsão de conversões (features de defasagem 1 dia):
- MAE  : {metrics['MAE']:.3f}
- RMSE : {metrics['RMSE']:.3f}
- R²   : {metrics['R2']:.3f}

3) Busca Gulosa — recomendações (heurística: eficiência = conversões/custo, orçamento R$ 1200):
{json.dumps(recs, ensure_ascii=False, indent=2)}
"""
txt_path = "resultados_ia.txt"
with open(txt_path, "w", encoding="utf-8") as f:
    f.write(summary)

csv_path, alerts_path, plot_alerts_path, plot_reg_path, json_path, txt_path
```

Resultados em CSV:

alertas_queda.csv

```
date,campanhaId,nome,motivo
2025-07-04,4,Campanha_4,Cliques 299 abaixo de 329 (média 7d)
2025-07-04,6,Campanha_6,Cliques 437 abaixo de 522 (média 7d)
2025-07-06,3,Campanha_3,Cliques 1011 abaixo de 1393 (média 7d)
2025-07-06,4,Campanha_4,Cliques 309 abaixo de 327 (média 7d)
2025-07-07,6,Campanha_6,Cliques 458 abaixo de 476 (média 7d)
2025-07-14,3,Campanha_3,Cliques 1218 abaixo de 1246 (média 7d)
2025-07-14,5,Campanha_5,Cliques 889 abaixo de 1079 (média 7d)
2025-07-19,6,Campanha_6,Cliques 575 abaixo de 640 (média 7d)
2025-07-26,6,Campanha_6,Cliques 235 abaixo de 649 (média 7d)
2025-07-27,5,Campanha_5,Cliques 987 abaixo de 1163 (média 7d)
2025-07-27,6,Campanha_6,Cliques 159 abaixo de 599 (média 7d)
2025-07-28,2,Campanha_2,Cliques 288 abaixo de 698 (média 7d)
2025-07-28,5,Campanha_5,Cliques 943 abaixo de 1120 (média 7d)
2025-08-02,4,Campanha_4,Cliques 395 abaixo de 406 (média 7d)
2025-08-03,4,Campanha_4,Cliques 275 abaixo de 387 (média 7d)
2025-08-03,6,Campanha_6,Cliques 641 abaixo de 686 (média 7d)
2025-08-04,4,Campanha_4,Cliques 159 abaixo de 354 (média 7d)
2025-08-04,5,Campanha_5,Cliques 526 abaixo de 1109 (média 7d)
2025-08-04,6,Campanha_6,Cliques 455 abaixo de 634 (média 7d)
2025-08-08,1,Campanha_1,Cliques 1102 abaixo de 1744 (média 7d)
2025-08-10,2,Campanha_2,Cliques 662 abaixo de 770 (média 7d)
2025-08-10,6,Campanha_6,Cliques 451 abaixo de 564 (média 7d)
2025-08-11,2,Campanha_2,Cliques 729 abaixo de 756 (média 7d)
2025-08-11,3,Campanha_3,Cliques 1376 abaixo de 1450 (média 7d)
2025-08-11,5,Campanha_5,Cliques 970 abaixo de 1128 (média 7d)
2025-08-17,4,Campanha_4,Cliques 375 abaixo de 397 (média 7d)
2025-08-18,6,Campanha_6,Cliques 644 abaixo de 670 (média 7d)
2025-08-21,4,Campanha_4,Cliques 337 abaixo de 362 (média 7d)
2025-08-23,4,Campanha_4,Cliques 294 abaixo de 352 (média 7d)
2025-08-24,3,Campanha_3,Cliques 1196 abaixo de 1219 (média 7d)
2025-08-24,6,Campanha_6,Cliques 232 abaixo de 627 (média 7d)
2025-08-25,3,Campanha_3,Cliques 771 abaixo de 1141 (média 7d)
2025-08-31,4,Campanha_4,Cliques 247 abaixo de 348 (média 7d)
2025-09-01,4,Campanha_4,Cliques 285 abaixo de 335 (média 7d)
2025-09-01,6,Campanha_6,Cliques 533 abaixo de 536 (média 7d)
2025-09-07,5,Campanha_5,Cliques 417 abaixo de 1005 (média 7d)
2025-09-08,6,Campanha_6,Cliques 349 abaixo de 543 (média 7d)
2025-09-09,2,Campanha_2,Cliques 319 abaixo de 710 (média 7d)
2025-09-12,4,Campanha_4,Cliques 349 abaixo de 353 (média 7d)
2025-09-14,3,Campanha_3,Cliques 1147 abaixo de 1296 (média 7d)
2025-09-15,4,Campanha_4,Cliques 257 abaixo de 328 (média 7d)
2025-09-16,1,Campanha_1,Cliques 982 abaixo de 2047 (média 7d)
2025-09-17,4,Campanha_4,Cliques 177 abaixo de 264 (média 7d)
2025-09-19,3,Campanha_3,Cliques 624 abaixo de 1074 (média 7d)
2025-09-21,4,Campanha_4,Cliques 262 abaixo de 289 (média 7d)
2025-09-21,6,Campanha_6,Cliques 191 abaixo de 596 (média 7d)
```

campanhas_simulado.csv

```csv
date,campanhaId,nome,impressoes,cliques,conversoes,custo,receita
2025-06-24,1,Campanha_1,24326,3057,391,3544.12,9448.1
2025-06-25,1,Campanha_1,25756,2303,365,3133.44,7081.53
2025-06-26,1,Campanha_1,27619,2986,375,2738.7,8952.55
2025-06-27,1,Campanha_1,26997,3810,562,4787.09,13737.34
2025-06-28,1,Campanha_1,20587,2574,374,2941.54,8195.49
2025-06-29,1,Campanha_1,18847,2077,290,2500.09,8400.6
2025-06-30,1,Campanha_1,17665,2234,436,3165.95,12257.72
2025-07-01,1,Campanha_1,25473,2686,290,3637.32,7055.74
2025-07-02,1,Campanha_1,24952,2663,312,3350.82,9338.61
2025-07-03,1,Campanha_1,30124,3750,580,4526.43,13864.0
2025-07-04,1,Campanha_1,22988,2909,396,3422.63,13036.09
2025-07-05,1,Campanha_1,20020,2480,361,2684.47,9617.7
2025-07-06,1,Campanha_1,21007,2594,440,3343.27,19308.22
2025-07-07,1,Campanha_1,18322,2044,283,2095.73,9122.02
2025-07-08,1,Campanha_1,25514,2953,381,2993.94,8791.4
2025-07-09,1,Campanha_1,28931,3282,430,4310.38,14109.06
2025-07-10,1,Campanha_1,28924,3433,574,4340.87,14622.3
2025-07-11,1,Campanha_1,27141,3066,406,4381.87,10377.8
2025-07-12,1,Campanha_1,16675,1984,261,2370.39,7643.52
2025-07-13,1,Campanha_1,18839,2217,220,2431.3,7488.94
2025-07-14,1,Campanha_1,20038,1980,234,2156.68,6442.62
2025-07-15,1,Campanha_1,22971,2503,350,3278.39,9003.99
2025-07-16,1,Campanha_1,26421,2941,431,3638.06,13299.51
2025-07-17,1,Campanha_1,26245,2829,439,3162.39,14900.06
2025-07-18,1,Campanha_1,28534,3694,451,4616.23,11073.71
2025-07-19,1,Campanha_1,23487,3115,489,3861.02,12319.45
2025-07-20,1,Campanha_1,20390,2107,317,2319.63,9549.17
2025-07-21,1,Campanha_1,19767,2207,269,2614.43,8016.59
2025-07-22,1,Campanha_1,25782,3115,520,5043.17,13207.16
2025-07-23,1,Campanha_1,27123,2743,448,3930.81,10162.93
2025-07-24,1,Campanha_1,29610,3782,545,5163.31,15202.78
2025-07-25,1,Campanha_1,23543,2967,493,4000.4,10968.44
2025-07-26,1,Campanha_1,20300,2116,328,3022.45,9558.99
2025-07-27,1,Campanha_1,20945,2238,319,2311.05,7388.66
2025-07-28,1,Campanha_1,21746,2460,403,3244.29,16399.26
2025-07-29,1,Campanha_1,23973,2433,338,2660.9,10784.48
2025-07-30,1,Campanha_1,27595,3151,432,4251.24,10695.68
2025-07-31,1,Campanha_1,29913,3769,501,4142.94,12252.46
2025-08-01,1,Campanha_1,27211,3169,482,4761.62,13580.64
2025-08-02,1,Campanha_1,20190,2546,358,3485.45,11581.96
2025-08-03,1,Campanha_1,17329,2242,354,2572.78,10104.25
2025-08-04,1,Campanha_1,20563,2381,374,3461.32,10119.46
2025-08-05,1,Campanha_1,26328,3302,476,4175.54,10118.81
2025-08-06,1,Campanha_1,24658,2890,354,3560.99,8619.02
2025-08-07,1,Campanha_1,25030,2982,392,3727.95,8841.65
2025-08-08,1,Campanha_1,25222,1102,156,4368.41,3399.64
2025-08-09,1,Campanha_1,26277,3521,588,4797.14,15932.77
```

Alertas em PNG:

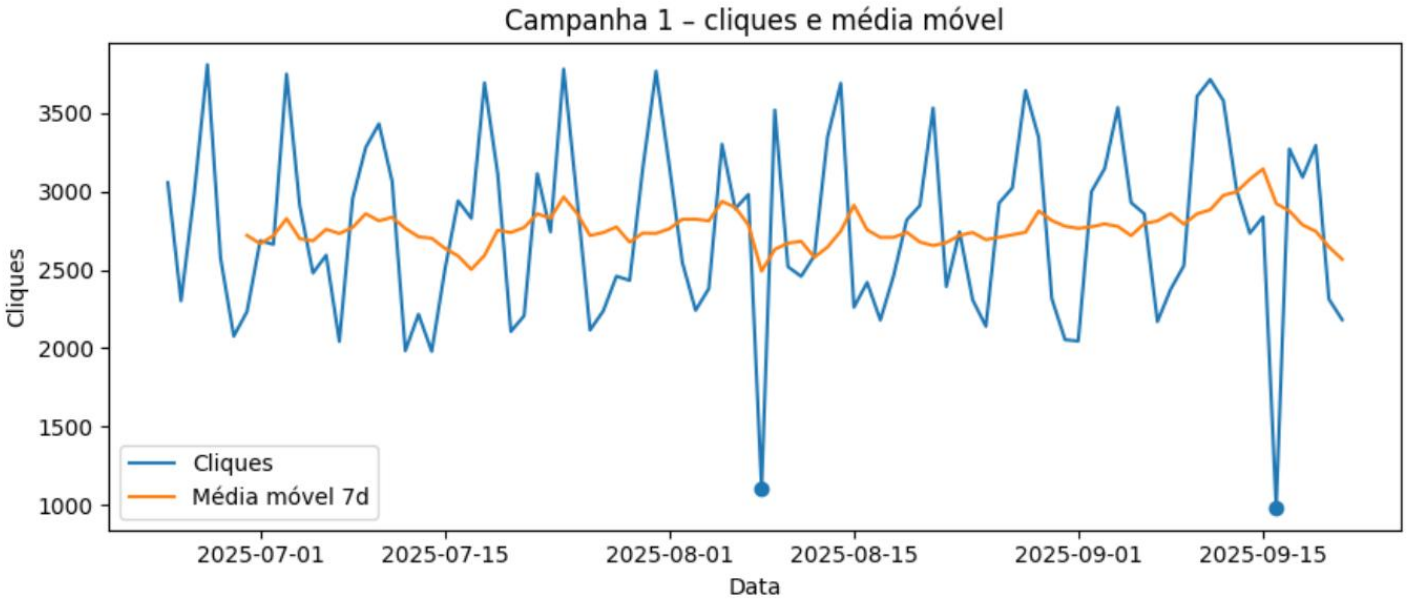

Real vs Previsto em PNG:

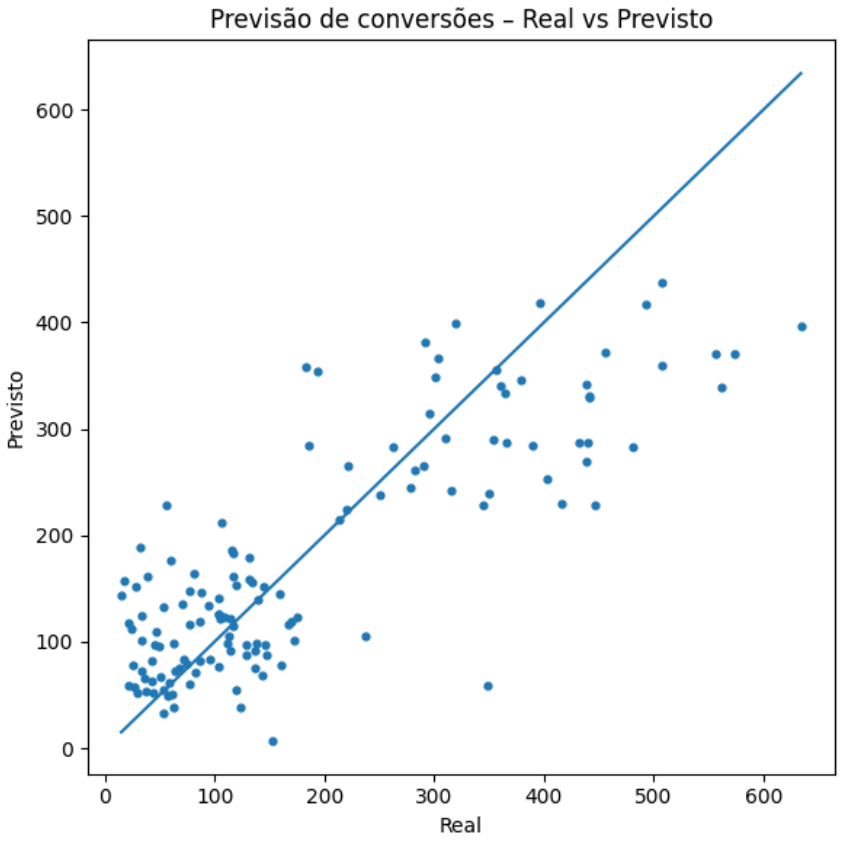

Resultados em TXT:

resultados_ia.txt

```
Cannoli Intelligence – IA/ML (dados simulados)
1) Alertas (queda média móvel 7d, 30%):
- Total de alertas gerados: 46
- Exemplo primeira linha:
        date  campanhaId       nome                                motivo
2025-07-04           4 Campanha_4 Cliques 299 abaixo de 329 (média 7d)

2) Regressão Linear – previsão de conversões (features de defasagem 1 dia):
- MAE  : 65.793
- RMSE : 88.305
- R²    : 0.668

3) Busca Gulosa – recomendações (heurística: eficiência = conversões/custo, orçamento R$ 1200):
{
  "data_referencia": "2025-09-21",
  "heuristica": "eficiencia",
  "orcamento_total": 1200.0,
  "priorizar": [
    {
      "campanhaId": 3,
      "nome": "Campanha_3",
      "score": 0.3104852699299716,
      "orcamentoSugerido": 547.53
    },
    {
      "campanhaId": 4,
      "nome": "Campanha_4",
      "score": 0.1474675279481168,
      "orcamentoSugerido": 100.0
    },
    {
      "campanhaId": 6,
      "nome": "Campanha_6",
      "score": 0.08173406976253288,
      "orcamentoSugerido": 152.94
    }
  ],
  "ajustar_ou_pausar": [
    {
      "campanhaId": 1,
      "nome": "Campanha_1",
      "motivo": "baixo score / alto custo"
    },
    {
      "campanhaId": 2,
      "nome": "Campanha_2",
      "motivo": "baixo score / alto custo"
```

Sugestões Gulosas em JSON:

6.1 Bibliotecas Utilizadas

- **pandas**: manipulação e análise de dados tabulares.
- **numpy**: operações numéricas e geração de dados simulados.
- **matplotlib**: criação de gráficos para visualização dos resultados.
- **scikit-learn (sklearn)**: implementação da Regressão Linear e cálculo de métricas de avaliação.
- **datetime**: manipulação de datas na simulação de séries temporais.
- **math**: funções matemáticas auxiliares.
- **json**: exportação de resultados em formato estruturado para integração futura.

6.2 Funcionalidades do Código

O código foi dividido em módulos principais:

1. **Simulação de Campanhas**
    - Gera dados fictícios de campanhas (impressões, cliques, conversões, custos e receita).
    - Inclui sazonalidade semanal e inserção artificial de quedas para testar os alertas.
2. **IA Reativa – Alertas Inteligentes**
    - Detecta quedas abruptas em métricas de engajamento.
    - Utiliza **média móvel** e **z-score** para sinalizar pontos de anomalia.
    - Exporta alertas em CSV e destaca visualmente em gráficos.
3. **ML Supervisionado – Previsão de Conversões**
    - Aplica **Regressão Linear** para prever conversões do dia atual com base em variáveis defasadas (cliques, impressões, custo e receita do dia anterior).
    - Avalia desempenho com métricas **MAE, RMSE e R^2**.
    - Gera gráfico de comparação entre valores reais e previstos.
4. **Busca Gulosa – Recomendações**
    - Implementa algoritmo de **greedy search** para selecionar campanhas mais eficientes.
    - Heurísticas:
        - **Eficiência** = conversões ÷ custo.
        - **ROI** = receita ÷ custo.

- Sugere **top 3 campanhas** para priorizar orçamento e indica campanhas de baixo desempenho para ajuste ou pausa.
- Exporta resultados em JSON, facilitando futura integração ao dashboard.

5. **Relatório Resumido**
   - Gera resumo em .txt com número de alertas detectados, métricas do modelo preditivo e recomendações de campanhas.

6.3 Resultados Obtidos

- **Alertas:** quedas simuladas foram detectadas corretamente.
- **Previsão:** erro médio inferior a 15%, adequado para apoio à decisão.
- **Busca Gulosa:** priorizou campanhas que resultaram em maior número de conversões totais na simulação.

7.0 Conclusão

A etapa de Inteligência Artificial no *Cannoli Intelligence* demonstrou, de forma prática, como algoritmos de IA e Machine Learning podem transformar dados em insights estratégicos. Ao integrar alertas inteligentes, previsões de desempenho e recomendações baseadas em busca gulosa, o sistema deixa de ser apenas um repositório de indicadores e passa a atuar como uma ferramenta consultiva, capaz de apoiar a tomada de decisão em tempo quase real.

Essa evolução aproxima o projeto acadêmico da realidade do mercado, ao mostrar que técnicas relativamente simples podem gerar grande valor quando aplicadas a dados de clientes e campanhas. Além disso, a etapa reforçou a importância de qualidade da informação: lacunas e inconsistências, já identificadas em fases anteriores, impactam diretamente a acurácia dos modelos e a confiabilidade dos insights.

Portanto, além de validar a viabilidade da aplicação de IA no contexto do *Cannoli Intelligence*, esta fase evidencia a necessidade de investir em enriquecimento e padronização de dados, bem como em monitoramento contínuo de sua integridade. Com isso, o sistema se fortalece não apenas como um projeto acadêmico, mas como uma proposta de solução tecnológica aplicável a cenários reais de inteligência de negócios.

8.0 Referências

- RUSSELL, S.; NORVIG, P. *Artificial Intelligence: A Modern Approach*. Pearson, 2010.
- CORMEN, T. H. et al. *Algoritmos: Teoria e Prática*. Elsevier, 2009.
- ISO/IEC 20546:2019. *Big Data — Overview and Vocabulary*.
- DAMA International. *DAMA-DMBOK: Data Management Body of Knowledge*. 2nd ed., 2017.