

**FUNDAÇÃO ESCOLA DE COMÉRCIO ÁLVARES PENTEADO
FECAP
ANÁLISE E DESENVOLVIMENTO DE SISTEMAS**

ALEXANDRA CHRISTINE SILVA RAIMUNDO - 24026156

CARLOS AUGUSTO SANTOS DE ALMEIDA - 20010535

HEBERT DOS REIS ESTEVES - 24026079

JOSÉ BENTO ALMEIDA GAMA - 24026127

CANNOLI INTELLIGENCE

PREPARAR OS DADOS

**São Paulo - SP
2025**

SUMÁRIO

01. INTRODUÇÃO	3
02. PREPARAÇÃO E ENRIQUECIMENTO DOS DADOS	4
02.1. Criação da base de estabelecimentos	4
02.2. Integração dos estabelecimentos nas bases principais	4
02.3. Geração de novos pedidos.....	6
03. TRATAMENTO E PREPARAÇÃO DOS DADOS.....	7
03.1. Leitura dos Arquivos CSV	7
03.2. Conversões Básicas de Tipo.....	8
03.3. Tratamento de Valores Nulos.....	10
03.4. Padronização e Criação de Novos Campos.....	11
03.5. Inferência de Gênero (Customer).....	13
03.6. Validações Finais	15
03.7. Exportação dos dados tratados	19
04. CARGA DAS BASES TRATADAS NO MYSQL	21
05. CONCLUSÃO	23

01. INTRODUÇÃO

Este relatório apresenta a segunda etapa do projeto Cannoli Intelligence, dedicada à preparação, enriquecimento e carga dos dados no banco de dados MySQL. O principal objetivo desta fase foi transformar as bases originais — inicialmente brutas, heterogêneas e inconsistentes — em conjuntos de dados limpos, padronizados e integrados, prontos para alimentar os dashboards analíticos e os módulos de inteligência da aplicação final.

Durante essa etapa, foram realizadas ações fundamentais para a consolidação do ambiente de dados, incluindo a criação de novas bases complementares, a integração entre diferentes fontes, o tratamento de valores nulos e inconsistentes, a padronização textual, e o enriquecimento automatizado com apoio de inteligência artificial. Por fim, os dados tratados foram importados e estruturados no MySQL, garantindo integridade relacional, consistência e compatibilidade com as futuras camadas de visualização e análise do sistema.

02. PREPARAÇÃO E ENRIQUECIMENTO DOS DADOS

02.1. Criação da base de estabelecimentos

Para viabilizar a autenticação individual de cada estabelecimento na aplicação, foi criada uma base denominada Estabelecimentos.csv. Essa base contém os campos establishment_id, store_name, segmento, cidade e UF. Foram gerados 12 estabelecimentos distintos, representando diferentes tipos de negócios e localidades. Essa estrutura serviu como referência principal para relacionar os dados de clientes, pedidos, campanhas e filas de mensagens com seus respectivos estabelecimentos.

establishment_id	storeName	segmento	cidade	uf
EST001	Pizzaria Bella Massa	Alimentacao	Sao Paulo	SP
EST002	Cafe do Centro	Bebidas	Campinas	SP
EST003	Hamburgueria Prime	Alimentacao	Rio de Janeiro	RJ
EST004	Cantina Italia	Alimentacao	Curitiba	PR
EST005	Doceria Sabor e Arte	Confeitaria	Belo Horizonte	MG
EST006	Restaurante Vila Gourmet	Alimentacao	Recife	PE
EST007	Churrascaria Gaucha	Alimentacao	Porto Alegre	RS
EST008	Padaria Delicia	Panificacao	Salvador	BA
EST009	Sorveteria Tropical	Confeitaria	Florianopolis	SC
EST010	Lanchonete Express	Fast Food	Brasilia	DF
EST011	Veg e Fit Saladas	Saudavel	Sao Paulo	SP
EST012	Temakeria Nippon	Sushi	Santos	SP

Figura 01 – Criação da base de estabelecimentos.

02.2. Integração dos estabelecimentos nas bases principais

Para que cada registro pudesse ser associado a um estabelecimento real, foi necessário realizar o mapeamento do campo establishment_id em todas as bases do projeto — Customer, Order, Campaign e CampaignQueue.

Esse processo foi conduzido com o apoio de IA generativa (ChatGPT), utilizada para automatizar o cruzamento e a distribuição coerente dos dados entre as 12 lojas criadas na base Estabelecimentos.csv.

A inteligência artificial analisou padrões de distribuição e criou a relação entre cada cliente, pedido, campanha e fila de mensagens com um storeId ou companyId específico.

Durante a execução, foram aplicadas regras de consistência para garantir que todos os relacionamentos entre tabelas fossem válidos, mantendo integridade

referencial entre os dados (por exemplo, cada campanha pertencer a uma loja existente e cada pedido estar vinculado a um cliente e a um estabelecimento real).

Com isso, foi possível preparar as bases para o funcionamento da autenticação no sistema web, permitindo que cada usuário (loja) visualize apenas seus próprios dados, enquanto o perfil de administrador mantém acesso consolidado a todos.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S
1	id	name	taxId	gender	dateOfBirth	status	externalCcs	isEnrichedA	enrichedB	createdAt	createdBy	updatedAt	updatedBy	phone	email	companyId			
2	1 Fernanda	1207.463.8.0				1	True	franciscoc	pferreira		wazevedo	5,52E+12	luigi67@h	EST007					
3	2 Matheus	J-46.792.50.M				2	False				ana-beatri	5,55E+12	otavio2@e	EST001					
4	3 João	E M 594.173.6.F				1 UZZPQK5	True	calebe40			luiz-fernar	5,56E+12	eduardasa	EST002					
5	4 Arthur	Silv 574.908.1.1				1	True	moraesluiz			vieiraguilh	5,58E+12	jcosta@uc	EST002					
6	5 Vicente	Te 937.825.1.NAN				1	False				goncalves	5,52E+12	oda-paz@	EST002					
7	6 Heloá	sa F 293.487.5.M				2	True	barbosasa			nina58	5,56E+12	pedro-luci	EST008					
8	7 Sr. Vicente	71.620.45.NAN				1 T3W5UZB	False				augustofo	5,50E+12	vieiragor	EST010					
9	8 Rodrigo	S 62.348.05.M				2 KWNNHJ7	True	otaviofoga			luiz-henric	5,56E+12	joao-guilh	EST002					
10	9 Alana	Pint-429.076.1.F				1	True	mirellamo			ocardoso	5,54E+12	mendeshe	EST008					
11	10 Vitor	Fern 815.732.6.F				2 41BLUH7	True	clarice53			rcampos	5,58E+12	augusto0C	EST009					
12	11 Guilherme	507.182.9.NAN				2 5XF0TOP	False				claricerrez	5,53E+12	da-costap	EST005					
13	12 Sra. Sarah	197.624.0.F				2 DBDW2PC	True	valentinad			idias	5,54E+12	ufrreitas@i	EST002					
14	13 Breno	Alve 327.096.5.M				1	True	emillyolive			barbosalu	5,52E+12	gmonteir	EST008					
15	14 Kevin	Peix 76.815.03.O				1	True	maysasou			carolinaal	5,52E+12	fbarros@g	EST002					
16	15 Matiá	Ara 609.423.5.M				2 81SDW4S	False				mirella25	5,57E+12	joao-guilh	EST007					
17	16 João	Ped 612.380.4.M				2 REN93IU	False				pietraang		xda-paz	5,53E+12	ida-costa@	EST006			
18	17 Nicolas	Mi-35.074.21.M				1	True	brynnbarb			leticciada-n	5,58E+12	miguelda-i	EST010					
19	18 Joana	Car 40.936.85.F				2	False				igomes		pedro-luci	5,55E+12	murilo56@	EST002			
20	19 Sr. Henrique	58.421.37.F				2 OYN6QIC	True	dda-mata			aragoa0n	5,54E+12	monteiron	EST008					
21	20 Kevin	Dias 218.954.3.M				1	False				kviana	5,55E+12	ana-caroli	EST005					
22	21 Julia	Nasc 960.713.4.M				2	True	thomasd			bfeiras	5,56E+12	aliciajesus	EST002					
23	22 Rodrigo	Az 238.540.9.NAN				1	True	ycosta			costaman	5,58E+12	uda-cunh	EST001					
24	23 João	E Mig 24.067.58.NAN				1	True	pedro-hen			davil57		jsantos	5,57E+12	nataliliada-	EST004			
25	24 Luiz	Henri-927.685.1.M				2	True	rgoncalves			icarvalho		isabel73	5,54E+12	davi-lucca	EST005			
26	25 Nicolas	de 894.032.6.M				1 C02DGTF	False				pedro-mig		raul89@u	EST002					

Figura 02 – Base Customer integrada aos estabelecimentos.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R
1	id	segment	template	storeId	name	description	badge	type	status	isDefault	createdAt	createdBy	updatedAt	updatedBy				
2	1	1	1 EST008	Campanh: Excepturi i seasonal	2	4	0	03/09/2024 11:20	padaria.m									
3	2	2	2 EST004	Campanh: Officia a f winback	2	4	0		cantina									
4	3	3	3 EST009	Campanh: Blendifiti i seasonal	2	3	1	06/06/2024 05:15	sorvetaria.									
5	4	4	4 EST007	Campanh: Atque mol winback	2	3	1	06/08/2024 06:33	churrascai									
6	5	5	5 EST001	Campanh: Ipsa nostri winback	2	2	0	05/08/2024 08:06	pizzaria.ar									
7	6	6	6 EST012	Campanh: Quo repellit seasonal	1	3	0		temakeria									
8	7	7	7 EST008	Campanh: Quos verit migration	1	2	0	03/05/2024 17:42	padaria.ca									
9	8	8	8 EST008	Campanh: Nao informi consumpt	1	1	1		padaria.m									
10	9	9	9 EST001	Campanh: Fugiat eos consumpt	2	4	0	10/05/2024 08:46	pizzaria.m									
11	10	5	10 EST004	Campanh: Quidem te consumpt	2	1	0		cantina.ar									
12	11	10	11 EST003	Campanh: Fugiat soli consumpt	2	2	0		hamburgu									
13	12	5	12 EST010	Campanh: In amet dii consumpt	2	4	0		lanchonet									
14	13	11	13 EST006	Campanh: Quia laud:winback	1	4	0	11/02/2024 15:39	restaurante									
15	14	12	14 EST008	Campanh: Nao informi migration	1	2	0		padaria.m									
16	15	13	15 EST004	Campanh: Rem quia i winback	1	4	0	05/05/2024 00:13	cantina.ca									
17	16	5	16 EST002	Campanh: Illo ipsa qu winback	1	2	0	10/05/2024 21:05	cafe.juliana									
18	17	14	17 EST005	Campanh: Earum cor winback	2	2	0		doceria.m									
19	18	15	18 EST001	Campanh: Delectus i consumpt	2	2	0	02/06/2024 09:54	pizzaria.ju									
20	19	5	19 EST008	Campanh: Nihil reicic consumpt	1	3	0		padaria.ca									
21	20	16	20 EST006	Campanh: Laudantium consumpt	1	4	0	04/12/2024 13:58	restaurant									
22	21	17	21 EST007	Campanh: Id quam fa Nao inform	1	1	0		churrascai									
23	22	18	22 EST003	Campanh: Sunt venia consumpt	1	2	0		hamburgu									
24	23	19	23 EST012	Campanh: Architecto winback	1	4	0	05/08/2024 11:42	temakeria.									
25	24	20	24 EST010	Campanh: Ipsam peri consumpt	1	1	0		lanchonet									

Figura 03 – Base Campaign integrada aos estabelecimentos

	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P
1	jobId	campaignId	storeId	storeInstai	customerI	phoneNuischeduledAt	sendAt	status	message	response	createdAt	createdBy	updatedAt	updatedBy	
2	1	1553	EST003	AXHTOYU	540	5.5E+12	23/01/2025 20:26	23/01/2025 22:23	5 Adipisci	placeat liber	23/01/2025 09:33	rsliva	24/01/2025 12:41	mirella55	
3	2	1890	EST004	QG71QPEI	702	5.6E+12	25/04/2025 01:48	25/04/2025 02:52	4 Reiciendi	Sit illo ulla	25/04/2025 01:04	lopesana	25/04/2025 11:14	zviana	
4	3	429	EST001	EKF1PQG	53	5.6E+12	04/11/2024 02:21		1 Voluptate	presentatio	03/11/2024 05:44	ana-livai2	03/11/2024 14:18	oda-cruz	
5	4	766	EST001	CNBOWCI	195	5.5E+12	03/07/2025 14:30	03/07/2025 15:30	5 Provident	quod repel	03/07/2025 01:11	juan20	04/07/2025 01:00	yasmimnello	
6	5	1039	EST004	OHNL2K6	5	5.5E+12	29/09/2024 07:36		6 In molestiae	quod dig	29/09/2024 02:15	souzagab	29/09/2024 15:21	nascimentomaitre	
7	6	1957	EST005	2ETABSFW	341	5.5E+12	06/05/2025 06:54	06/05/2025 08:07	5 Quisquam	doloribus	06/05/2025 05:02	nuneslun	06/05/2025 14:45	da-pavitor	
8	7	1292	EST006	91HQ1EO	715	5.6E+12	10/11/2024 11:56	10/11/2024 13:29	2 Exercitationem	reprel	09/11/2024 22:48	isaac53	09/11/2024 23:22	munes	
9	8	679	EST001	SNZAYBVJ	479	5.5E+12	01/10/2024 22:45	02/10/2024 00:45	2 Tenetur	ni Voluptate	01/10/2024 18:22	isadora97	03/10/2024 03:13	maria-ceciliamartins	
10	9	1598	EST001	OBTB1632	981	5.6E+12	31/08/2025 23:57	01/09/2025 01:03	2 Asperiores	Voluptatib	31/08/2025 00:35	barbaranib	31/08/2025 18:26	martinsdanilo	
11	10	2000	EST005	9K5HGH	712	5.6E+12	08/07/2025 16:33	08/07/2025 17:04	2 Error iste	e Naturu	08/07/2025 15:44	gustavo84	08/07/2025 17:49	sabrinaalma	
12	11	285	EST005	WFG29WL	349	5.6E+12	04/11/2024 16:49	04/11/2024 17:58	2 Optio quia	vel distinc	03/11/2024 19:42	lcavalcant	04/11/2024 16:21	davi-luccasila	
13	12	1277	EST002	7B8R8AD01	398	5.5E+12	31/10/2024 21:25	31/10/2024 23:39	3 Iusto quas	Quae acc.	31/10/2024 18:11	kaike37	01/11/2024 12:03	vfragaca	
14	13	763	EST001	OTGIWFCL	148	5.6E+12	15/04/2024 14:16		1 Fugit	quod ex nihil	pe 14/04/2025 20:23	julianamel	16/04/2025 02:17	da-romacharia-fernanda	
15	14	18	EST001	QUDF0BD	883	5.6E+12	30/10/2024 11:50	30/10/2024 12:16	4 A ea temp	consequi	30/10/2024 00:26	camposhe	30/10/2024 02:16	rezenednicole	
16	15	1932	EST006	HZVE9062	999	5.5E+12	25/06/2025 11:11	25/06/2025 13:42	4 Voluptate	laudanti	25/06/2025 08:20	talves	26/06/2025 12:29	kda-cruz	
17	16	1062	EST006	BRUIGU9	934	5.6E+12	28/12/2024 12:08	28/12/2024 14:08	5 Facilis	sapiente mag	27/12/2024 17:08	rafaelagon	27/12/2024 18:39	gabrielacastro	
18	17	884	EST004	T12FBQJI	79	5.6E+12	07/05/2025 21:23		6 Voluptatib	Aliquam st	07/05/2025 07:28	da-cruzui	07/05/2025 07:36	teixeiraamanda	
19	18	534	EST006	YCXBX0XC	118	5.6E+12	02/05/2025 09:11		1 Quia aliqui	Minima ius	01/05/2025 22:47	gabriellyc	02/05/2025 05:47	raquelviana	
20	19	1266	EST008	1S2XUB0	650	5.5E+12	24/07/2025 05:44	24/07/2025 08:13	2 Doloremque	inventor	23/07/2025 20:54	luizca67			
21	20	1727	EST003	ZDDQ81G	241	5.6E+12	04/02/2025 17:36	04/02/2025 18:42	3 Est ipsam	Minus dolo	03/02/2025 23:45	da-rochao	04/02/2025 02:22	rsozua	
22	21	903	EST001	HDTI7L9	194	5.6E+12	17/01/2025 14:21	17/01/2025 15:44	4 Itaque	accusantium	17/01/2025 05:29	gustavo-h	18/01/2025 12:26	dmorales	
23	22	1255	EST001	KM4530B	491	5.6E+12	26/11/2024 22:33	27/11/2024 00:37	1 Areciend	Expedita	26/11/2024 12:37	ryanima	26/11/2024 20:34	kevinicamp	
24	23	958	EST001	WORQ2L	72	5.6E+12	20/03/2025 06:14		1 Provident	odio cupid	19/03/2025 07:23	kda-costa	19/03/2025 12:06	cda-conceicao	
25	24	1396	EST001	LSQY38YK	122	5.6E+12	24/10/2024 15:11	24/10/2024 16:21	3 Nemo	a quod quasi n	23/10/2024 15:59	ana-vitorz	24/10/2024 17:31	mrezende	

Figura 04 – Base CampaignQueue integrada aos estabelecimentos

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W	X	
1	id	company	container	createdAt	customer	engId	engInName	engType	extraInfo	integrated	isTest	orderTimir	orderType	salesChanscheduledAt	status	preparatio	takeOut	totalAmount	updatedAt	updatedAt	version				
2	1	EST011	AKVXT2FH	08/01/2025 15:47	525	OBRC0B	E3R037	DirectOrD-POS	Adipisci m	True	2452	4688	True	IMMEDIATE DELIVERY ANOTAAI	DISPATCH	45	2131	90.91	09/01/2025 03:32	v3.7.8					
3	2	EST004	KKMY5TGH	03/11/2024 22:30	694	HJ99VA	EV0BV	DirectOrD-APP	False	8501	False	4688	True	IMMEDIATE DELIVERY WHATSAPP	CONCLUD	33	374	99.69	04/11/2024 03:32	v2.3.0					
4	3	EST004	IB7JL0TV	09/09/2024 05:49	491	JCHJ2H	UDX12F	KDSPro	POS	True	8501	False	4688	True	IMMEDIATE INDOOR EPADOCIA	CONCLUD	22	247	45.97	09/09/2024 09:32	v1.9.5				
5	4	EST004	WZ2XQON	22/05/2025 06:22	846	IQ0PM3	30FLC	KDSPro	WEB	Autem mo	3560	False	4688	True	IMMEDIATE TAKEOUT 99FOOD	DISPATCH	35	1766	104.31	22/05/2025 13:09	v2.8.5				
6	5	EST006	NAACOF0	22/02/2025 01:23	77	H4V7	QJ3URN	KDSPro	POS	True	3196	False	4688	True	IMMEDIATE DELIVERY 99FOOD	DISPATCH	20	1219	105.5	22/02/2025 13:53	v2.1.3				
7	6	EST002	NGNYXIK	17/12/2024 14:54	463	WSVJ73	MIXWGY	KDSPro	APP	True	1550	False	4688	True	IMMEDIATE INDOOR 99FOOD	DISPATCH	68	1689	51.42	18/12/2024 09:12	v2.8.3				
8	7	EST011	FSQ4MYXK	17/05/2025 16:51	625	TXA2WV	6IL4M	CanollEn	POS	False	5252	False	4688	True	IMMEDIATE TAKEOUT SITE	DISPATCH	43	2922	118.33	18/05/2025 12:12	v2.8.8				
9	8	EST001	QR7DE65T	12/06/2025 15:22	385	WHT75	RCAXH0	CanollEn	APP	Consectet	7965	False	4688	False	IMMEDIATE INDOOR 99FOOD	DISPATCH	20	1797	21.41	03/06/2025 03:56	v1.4.6				
10	9	EST001	Q97D65P	12/06/2025 02:18	633	DXWVH	TMHFL	CanollEn	WEB	False	4688	False	4688	False	IMMEDIATE DELIVERY 99FOOD	DISPATCH	33	3243	10.36	11/06/2025 18:50	v2.3.4				
11	10	EST004	1PZD5P	19/05/2025 09:27	359	WQH542	DCS02	FoodBridge	APP	True	8502	False	4688	True	IMMEDIATE DELIVERY 99FOOD	DISPATCH	51	1041	48.3	17/12/2024 01:56	v1.2.1				
12	11	EST009	QZRMTHQ	11/10/2024 18:49	34	HGBQH	MEQ5OS	FoodBridge	APP	True	2094	False	4688	True	IMMEDIATE INDOOR EPADOCIA	DISPATCH	88	3548	39.21	12/10/2024 01:42	v2.4.4				
13	12	EST009	ISUPYF01	15/04/2025 20:30	992	EF00P	PT04G	DirectOrD-POS	POS	False	2094	False	4688	True	IMMEDIATE DELIVERY EPAPI	DISPATCH	92	2455	107.72	10/04/2025 01:10	v1.9.8				
14	13	EST012	10988BM	18/11/2024 07:53	518	AVY755	CZH3H	FoodBridge	APP	True	1015	False	4688	True	IMMEDIATE INDOOR ANOTAAI	DISPATCH	30	820	14.15	16/11/2024 00:38	v1.1.1				
15	14	EST006	952B5IRK	14/01/2025 09:12	932	OBRI4M	UITH09	CanollEn	APP	Vitae eaque.	False	9517	False	4688	True	IMMEDIATE DELIVERY FOOD	PENDING	48	3435	44.53	15/01/2025 04:58	v3.3.6			
16	15	EST008	BEHHW98	13/03/2025 03:19	19	2MPGLQ	UJ083T	KDSPro	WEB	True	9117	False	4688	True	IMMEDIATE DELIVERY 99FOOD	DISPATCH	40	2318	114.57	03/05/2025 13:26	v3.5.5				
17	16	EST007	CHHD0AS	10/10/2024 13:12	365	CO1RWY	YMC5SY	DirectOrD-Web	Web	False	1701	False	4688	True	IMMEDIATE INDOOR WHATSAPP	PLACED	82	1126	140.07	11/10/2024 08:40	v1.9.0				
18	17	EST009	1FTNTUY5	17/07/2025 16:58	34	HCJ072	JAVIEI	KDSPro	POS	Eius quo d	2177	False	4688	True	IMMEDIATE TAKEOUT IFOOD	DISPATCH	54	367	46.37	08/07/2025 11:33	v2.0.0				
19	18	EST002	KL5ZNJN	19/12/2024 00:30	39	C7T7ZY	QIJQCAW	FoodBridge	POS	True	6461	False	4688	True	IMMEDIATE DELIVERY DIVERVIP	CONFIRM	18	2992	98.13	19/12/2024 11:03	v2.1.1				
20	19	EST002	E30ZQDZ	12/08/2025 09:43	99	AC2HZE	Q3MN9X	FoodBridge	POS	Qui assur	4622	False	4688	True	IMMEDIATE TAKEOUT WHATSAPP	CANCELLED	29	1650	37.15	13/08/2025 03:27	v3.4.1				
21	20	EST002	4UXMWAT	05/12/2024 07:26	301	BFXP1F	BRDZRQ	CanollEn	POS	Nostrum i	7106	False	4688	True	IMMEDIATE TAKEOUT IFOOD	CONFIRM	63	2405	47.72	05/12/2024 17:12	v3.1.5				
22	21	EST002	KSTYUCF	11/01/2025 07:45	348	GWXQQL	DZFLM	DirectOrD-Web	Web	True	2822	False	4688	True	IMMEDIATE DELIVERY FOOD	CONFIRM	51	3181	18.53	11/01/2025 18:33	v2.2.5				
23	22	EST005	X5BAM6R	26/09/2024 07:01	233	ERR7EB	LQWWK	DirectOrD-Web	Web	Quisar	4011	False	4688	True	IMMEDIATE INDOOR ANOTAAI	CONFIRM	80	1846	33.69	26/09/2024 11:54	v3.4.1				
24	23	EST001	ABED5R8E	23/11/2024 23:42	66	H6BC52	R3AEKZ	FoodBridge	POS	Voluptas q	3265	False	4688	True	IMMEDIATE DELIVERY SITE	CONCLUD	15	3370	40.94	24/11/2024 02:25	v2.3.3				
25	24	EST009	SZLCNTC	07/02/2025 13:25	115	IHC7EX	SAOE0	KDSPro	APP	True	9347	False	4688	True	IMMEDIATE TAKEOUT WHATSAPI	CONFIRM	53	3094	70.15	08/02/2025 03:36	v3.3.7				
26	25	EST004	RULBRIS	15/07/2025 07:07	71	JTP790	PBL120	CanollEn	POS	Ea numquam	9623	False	4688	True	IMMEDIATE TAKEOUT IFOOD	DISPATCH	13	2214	16.35	15/07/2025 23:02	v1.7.7				
27	26	EST003	XXDQH5W	10/05/2025 02:34	661	S21N20	TD05	URBNT	DirectOrD-APP	True	1965	False	4688	True	IMMEDIATE DELIVERY WHATSAPP	CANCELLED	14	74	24.89</td						

O algoritmo foi configurado para simular tendências temporais e comportamentos comerciais típicos, criando pedidos mais recentes (de meses próximos a 2024 e 2025), o que enriquece as análises temporais nos dashboards.

Os registros foram distribuídos proporcionalmente entre os 12 estabelecimentos, garantindo diversidade e volume equilibrado.

Esse processo resultou em uma base mais robusta e representativa, ideal para visualização de métricas como ticket médio, receita por canal e volume mensal de vendas.



```
[5]  Os  ⏎ import pandas as pd
[6]  Os  ⏎ order = pd.read_csv("Order.csv", sep=";")
[7]  Os  ⏎ for nome, df in {"Order":order}.items():
      print(f"{nome}: {df.shape[0]} linhas x {df.shape[1]} colunas")
... Order: 3500 linhas x 23 colunas
```

Figura 06 – Ampliação da base de pedidos.

03. TRATAMENTO E PREPARAÇÃO DOS DADOS

O processo de tratamento e preparação dos dados foi realizado no Google Colab, utilizando as bibliotecas pandas e numpy. O objetivo foi transformar as bases enriquecidas da plataforma Cannoli em conjuntos de dados limpos, consistentes e prontos para integração com o banco de dados MySQL e os dashboards interativos. O fluxo de trabalho foi estruturado em sete etapas principais: leitura dos arquivos, conversões de tipo, tratamento de valores nulos, padronização e criação de novos campos, inferência de gênero, validações finais e exportação dos arquivos tratados. Cada etapa foi cuidadosamente documentada e implementada para garantir a integridade e qualidade dos dados.

03.1. Leitura dos Arquivos CSV

Na primeira etapa, foram lidas as quatro bases principais do projeto: Order.csv, Campaign.csv, CampaignQueue.csv e Customer.csv. O carregamento foi feito utilizando o separador “,” e, após a leitura, foi realizada a verificação da estrutura de cada arquivo, exibindo o número de linhas e colunas no console. Essa verificação permitiu confirmar que todos os arquivos haviam sido corretamente importados após o enriquecimento com os identificadores dos estabelecimentos e a geração de novos pedidos.

A base Order, por exemplo, passou a conter 3.500 registros (2.000 originais mais 1.500 gerados artificialmente para simular novos pedidos recentes), totalizando 23 colunas. As demais bases — Campaign, CampaignQueue e Customer — mantiveram suas quantidades esperadas de linhas e colunas, já com os campos de relacionamento (companyId e storeId) devidamente populados e consistentes com a tabela de estabelecimentos.

```

▼ 1) Leitura dos CSVs

[1] ✓ 0s
    import pandas as pd
    import numpy as np

[2] ✓ 0s
    order      = pd.read_csv("Order.csv", sep=";")
    campaign   = pd.read_csv("Campaign.csv", sep=";")
    campaign_queue = pd.read_csv("CampaignQueue.csv", sep=";")
    customer   = pd.read_csv("Customer.csv", sep=";")
    for nome, df in {"Order":order,"Campaign":campaign,"CampaignQueue":campaign_queue,"Customer":customer}.items():
        print(f"{nome}: {df.shape[0]} linhas x {df.shape[1]} colunas")

    Order: 3500 linhas x 23 colunas
    Campaign: 2000 linhas x 14 colunas
    CampaignQueue: 5000 linhas x 16 colunas
    Customer: 1000 linhas x 17 colunas
  
```

Figura 07 – Leitura dos arquivos CSV e exibição das dimensões das bases (linhas e colunas).

03.2. Conversões Básicas de Tipo

A segunda etapa teve como foco garantir que todas as colunas possuíssem o tipo de dado adequado para análise.

Na base Order, as colunas de data (createdAt, updatedAt e scheduledAt) foram convertidas para o tipo datetime, e a coluna totalAmount — originalmente armazenada como texto com separadores inconsistentes — foi tratada e convertida em formato numérico em uma nova coluna chamada totalAmount_num. As variáveis textuais (salesChannel, engineName, engineType, orderType, orderTiming e version) foram padronizadas para texto simples, com remoção de espaços em branco e caracteres indesejados.

Na base Campaign, as colunas de data (createdAt, updatedAt, _createdAt) também foram convertidas para datetime, e os campos textuais (badge, description, type e storeId) foram padronizados e limpos.

Na base CampaignQueue, as datas (scheduledAt, sendAt, createdAt, updatedAt) foram tratadas, e as colunas textuais (message, response, storeId, storeInstanceId) foram normalizadas.

Já na base Customer, campos de data (dateOfBirth, createdAt, updatedAt, enrichedAt) foram convertidos para datetime, e campos de identificação (name, gender, externalCode, email, phone) foram tratados e convertidos para texto padronizado.

Essas conversões foram essenciais para viabilizar cálculos temporais, agrupamentos mensais e filtragens por status em etapas posteriores.

- ▼ 2) Conversões básicas de tipo (datas, números, textos)
- ▼ 2.1) Customer — datas e textos

```
[3] ✓ 0s
customer_cl = customer.copy()

for col in ["dateOfBirth", "createdAt", "updatedAt", "enrichedAt"]:
    if col in customer_cl.columns:
        customer_cl[col] = pd.to_datetime(customer_cl[col], errors="coerce", dayfirst=True)

for col in ["name", "gender", "externalCode", "email", "phone"]:
    if col in customer_cl.columns:
        customer_cl[col] = customer_cl[col].astype(str).str.strip()

if "gender" in customer_cl.columns:
    customer_cl["gender"] = customer_cl["gender"].str.upper()
```

- ▼ 2.2) Campaign — datas e textos

```
[4] ✓ 0s
campaign_cl = campaign.copy()

for col in ["createdAt", "updatedAt", "_createdAt"]:
    if col in campaign_cl.columns:
        campaign_cl[col] = pd.to_datetime(campaign_cl[col], errors="coerce", dayfirst=True)

for col in ["badge", "name", "description", "type", "storeId"]:
    if col in campaign_cl.columns:
        campaign_cl[col] = campaign_cl[col].astype(str).str.strip()
```

Figura 8 – Conversão de colunas de texto, datas e valores numéricos nas bases de Customer e Campaign.

The screenshot shows a Jupyter Notebook interface with two code cells. The first cell, titled '2.3) CampaignQueue – datas, textos e status numérico', contains Python code for converting columns in the 'campaign_queue' DataFrame. It uses pd.to_datetime() for datetime columns and pd.to_numeric() for the 'status' column, handling errors with 'coerce'. The second cell, titled '2.4) Order – datas, números e textos', contains Python code for the 'order' DataFrame. It converts 'totalAmount' to a numeric type by removing commas and periods, then converts it to a float. It also strips whitespace from other string columns like 'salesChannel' and 'engineName'. Both cells have a duration of 0s.

```
[5] 0s
campaign_queue_cl = campaign_queue.copy()

for col in ["scheduledAt", "sendAt", "createdAt", "updatedAt"]:
    if col in campaign_queue_cl.columns:
        campaign_queue_cl[col] = pd.to_datetime(campaign_queue_cl[col], errors="coerce", dayfirst=True)

for col in ["message", "response", "storeId", "storeInstanceId"]:
    if col in campaign_queue_cl.columns:
        campaign_queue_cl[col] = campaign_queue_cl[col].astype(str).str.strip()

if "status" in campaign_queue_cl.columns:
    campaign_queue_cl["status"] = pd.to_numeric(campaign_queue_cl["status"], errors="coerce")

[6] 0s
order_cl = order.copy()

for col in ["createdAt", "scheduledAt", "updatedAt", "_createdAt"]:
    if col in order_cl.columns:
        order_cl[col] = pd.to_datetime(order_cl[col], errors="coerce", dayfirst=True)

if "totalAmount" in order_cl.columns:
    order_cl["totalAmount_num"] = (
        order_cl["totalAmount"]
        .astype(str)
        .str.replace(".", "", regex=False)
        .str.replace(",", ".", regex=False)
    )
    order_cl["totalAmount_num"] = pd.to_numeric(order_cl["totalAmount_num"], errors="coerce")

for col in ["salesChannel", "engineName", "engineType", "orderType", "orderTiming", "version"]:
    if col in order_cl.columns:
        order_cl[col] = order_cl[col].astype(str).str.strip()
```

Figura 9 – Conversão de colunas de texto, datas e valores numéricos nas bases de CampaignQueue e Order.

03.3. Tratamento de Valores Nulos

Na terceira etapa, foram aplicadas regras específicas para o tratamento de valores nulos, garantindo coerência sem distorcer as informações.

Na base Order, as colunas extraInfo e scheduledAt permaneceram nulas quando apropriado, já que indicam pedidos sem metadados ou sem agendamento.

Na base Campaign, campos como badge, description, name e type tiveram valores ausentes substituídos por "Nao informado", evitando lacunas em relatórios.

Na base CampaignQueue, os campos message e response também receberam o preenchimento "Nao informado", enquanto sendAt permaneceu nulo para representar mensagens ainda não enviadas.

Por fim, na base Customer, o campo externalCode teve seus nulos substituídos por "Nao informado", enquanto os campos enrichedAt e enrichedBy permaneceram vazios, indicando clientes que ainda não foram enriquecidos.

Essa abordagem priorizou manter o significado dos nulos quando eles representam ausência legítima de informação (por exemplo, mensagens pendentes), ao mesmo tempo em que padronizou os demais valores para análise e visualização.

```

    ▼ 3) Tratamento de valores nulos

        ▼ 3.1) Order

[7] ✓ Os
    for col in ["engineName", "engineType", "orderType", "orderTiming", "salesChannel", "version"]:
        if col in order_cl.columns:
            order_cl[col] = order_cl[col].fillna("Nao informado")

        if "extraInfo" in order_cl.columns:
            order_cl["extraInfo"] = order_cl["extraInfo"].fillna("")

    ▼ 3.2) Campaign

[8] ✓ Os
    for col in ["badge", "description", "name", "type"]:
        if col in campaign_cl.columns:
            campaign_cl[col] = campaign_cl[col].replace({np.nan: ""}).fillna("Nao informado")

    ▼ 3.3) CampaignQueue

[9] ✓ Os
    if "message" in campaign_queue_cl.columns:
        campaign_queue_cl["message"] = campaign_queue_cl["message"].fillna("Nao informado")

    if "response" in campaign_queue_cl.columns:
        campaign_queue_cl["response"] = campaign_queue_cl["response"].replace({":": np.nan}).fillna("Nao informado")

    ▼ 3.4) Customer

[10] ✓ Os
    if "externalCode" in customer_cl.columns:
        customer_cl["externalCode"] = customer_cl["externalCode"].replace({":": np.nan}).fillna("Nao informado")

```

Figura 10 – Trecho de código mostrando a aplicação de regras de preenchimento e tratamento de valores nulos.

03.4. Padronização e Criação de Novos Campos

Após o tratamento de nulos, iniciou-se a etapa de padronização e derivação de novos campos.

Primeiramente, o campo storeId foi padronizado para letras maiúsculas em todas as tabelas que o continham, garantindo consistência com os identificadores dos estabelecimentos.

Em seguida, foram criadas colunas descritivas de status (`status_desc`) para traduzir códigos numéricos em rótulos textuais.

Na base Customer, os códigos 1 e 2 foram transformados em “Ativo” e “Inativo”; na base Campaign, em “Rascunho”, “Agendada”, “Ativa” e “Concluída”; e na base CampaignQueue, em “Pendente”, “Enviada”, “Entregue”, “Lida”, “Erro” e “Cancelada”.

Além disso, foram criadas colunas de mês (`_mes`) em todas as bases para permitir a análise temporal dos registros.

Na base Order, o mês foi extraído da coluna `createdAt`.

Na base Campaign, o campo `_mes` foi derivado da nova coluna `createdAt_filled`, que utiliza o valor de `updatedAt` quando `createdAt` está ausente.

Na base CampaignQueue, o campo `_mes` foi calculado a partir das colunas `sendAt`, `scheduledAt` e `createdAt`, priorizando a data mais representativa.

Por fim, na base Customer, foi criado o campo `isEnriched_text`, que converte valores booleanos (True/False) em texto (“Enriquecido” ou “Nao Enriquecido”), melhorando a legibilidade das informações em painéis analíticos.

Essas padronizações garantiram a coerência entre as tabelas e facilitaram a geração de indicadores consolidados.

4) Padronização e criação de novos campos

```
[11] ✓ Os
# Transforma storeId maiúsculo em todas as bases que possuem essa coluna
for df in (order_cl, campaign_cl, campaign_queue_cl):
    if "storeId" in df.columns:
        df["storeId"] = df["storeId"].astype(str).str.strip().str.upper()

[12] ✓ Os
# Campo textual para enriquecimento de clientes
if "isEnriched" in customer_cl.columns:
    customer_cl["isEnriched_text"] = customer_cl["isEnriched"].map(
        {True: "Enriquecido", False: "Não Enriquecido"}
    )

[13] ✓ Os
# Status legíveis (sem acentos para evitar problemas de encoding)
map_status_customer = {1: "Ativo", 2: "Inativo"}
map_status_campaign = {1: "Rascunho", 2: "Agendada", 3: "Ativa", 4: "Concluída"}
map_status_queue = {
    1: "Pendente",
    2: "Enviada",
    3: "Entregue",
    4: "Lida",
    5: "Erro",
    6: "Cancelada",
}
if "status" in customer_cl.columns and customer_cl["status"].dtype != "O":
    customer_cl["status_desc"] = customer_cl["status"].map(map_status_customer).fillna("Não informado")
if "status" in campaign_cl.columns and campaign_cl["status"].dtype != "O":
    campaign_cl["status_desc"] = campaign_cl["status"].map(map_status_campaign).fillna("Não informado")
if "status" in campaign_queue_cl.columns and campaign_queue_cl["status"].dtype != "O":
    campaign_queue_cl["status_desc"] = campaign_queue_cl["status"].map(map_status_queue).fillna("Não informado")

[14] ✓ Os
# Criação de campo de mês (_mes) em todas as bases

# Order: mês a partir de createdAt
if "createdAt" in order_cl.columns:
    order_cl["_mes"] = order_cl["createdAt"].dt.to_period("M").astype(str)

# Campaign: preencher createdAt nulo com updatedAt e criar _mes
if "createdAt" in campaign_cl.columns:
    if "updatedAt" in campaign_cl.columns:
        campaign_cl["createdAt_filled"] = campaign_cl["createdAt"].fillna(campaign_cl["updatedAt"])
    else:
        campaign_cl["createdAt_filled"] = campaign_cl["createdAt"]
        campaign_cl["_mes"] = pd.to_datetime(
            campaign_cl["createdAt_filled"], errors="coerce"
        ).dt.to_period("M").astype(str)

# CampaignQueue: mês considerando sendAt / scheduledAt / createdAt
if "sendAt" in campaign_queue_cl.columns:
    base_dt = campaign_queue_cl["sendAt"]
    if "scheduledAt" in campaign_queue_cl.columns:
        base_dt = base_dt.fillna(campaign_queue_cl["scheduledAt"])
    if "createdAt" in campaign_queue_cl.columns:
        base_dt = base_dt.fillna(campaign_queue_cl["createdAt"])
    campaign_queue_cl["_mes"] = pd.to_datetime(
        base_dt, errors="coerce"
    ).dt.to_period("M").astype(str)
```

Figura 11 – Padronização de campos, criação de colunas de status e derivação do campo mensal (_mes).

03.5. Inferência de Gênero (Customer)

Uma etapa específica foi dedicada ao enriquecimento da base Customer, com foco na inferência de gênero.

Para complementar registros incompletos e padronizar os valores existentes, foi utilizada a biblioteca gender_guesser, que infere o gênero a partir do primeiro nome.

Primeiro, os nomes foram normalizados e o primeiro nome de cada cliente foi extraído. Em seguida, os valores válidos de gênero foram mantidos, enquanto os registros com campos vazios ou inválidos passaram pelo processo de inferência.

O algoritmo retorna rótulos como “male”, “female”, “mostly_male”, “mostly_female” ou “unknown”, que foram convertidos em “M”, “F” ou “Nao informado”.

Os resultados foram armazenados nas colunas gender_inferred e gender_final, consolidando todos os casos em uma versão padronizada denominada gender_clean.

Esse processo aumentou significativamente a qualidade da base, permitindo segmentações mais precisas e mantendo consistência em todos os registros.

```
[15] ✓ ls
    pip install gender-guesser
    Collecting gender-guesser
        Downloading gender_guesser-0.4.0-py2.py3-none-any.whl.metadata (3.0 kB)
        Downloading gender_guesser-0.4.0-py2.py3-none-any.whl (379 kB)
            379.3/379.3 kB 18.9 MB/s eta 0:00:00
    Installing collected packages: gender-guesser
    Successfully installed gender-guesser-0.4.0

[16] ✓ os
    try:
        import gender_guesser.detector as gender
        det = gender.Detector(case_sensitive=False)
        pode_inferir = True
    except Exception:
        print("gender-guesser não disponível. Prosseguindo sem inferência automática.")
        det = None
        pode_inferir = False

    def pegar_primeiro_nome(nome):
        if pd.isna(nome):
            return None
        texto = str(nome).strip()
        if not texto:
            return None
        return texto.split()[0]

    def traduzir_guess(g):
        if g in ["male", "mostly_male"]:
            return "M"
        if g in ["female", "mostly_female"]:
            return "F"
        return "Nao informado"

    if "gender" in customer_cl.columns and "name" in customer_cl.columns:
        customer_cl["gender"] = customer_cl["gender"].str.upper()
        validos = customer_cl["gender"].isin(["M", "F", "O"])
        mascara_invalido = ~validos

        if pode_inferir and mascara_invalido.any():
            primeiros = customer_cl.loc[mascara_invalido, "name"].apply(pegar_primeiro_nome)
            palpites = primeiros.apply(
                lambda n: det.get_gender(n) if isinstance(n, str) else "unknown"
            )
            inferido = palpites.apply(traduzir_guess)
            customer_cl.loc[mascara_invalido, "gender_inferred"] = inferido
            customer_cl.loc[mascara_invalido, "gender_final"] = np.where(
                inferido.isin(["M", "F"]),
                inferido,
                "Nao informado"
            )
        else:
            customer_cl.loc[mascara_invalido, "gender_final"] = "Nao informado"

        customer_cl.loc[validos, "gender_final"] = customer_cl.loc[validos, "gender"]
        customer_cl.loc[customer_cl["gender"] == "O", "gender_final"] = "O"
        customer_cl["gender_clean"] = customer_cl["gender_final"]

    print("Distribuição (gender_clean):")
    print(customer_cl["gender_clean"].value_counts(dropna=False))

... Distribuição (gender_clean)
gender_clean
F           344
M           309
O            263
Nao informado   84
Name: count, dtype: int64
```

Figura 12 – Trecho de código e saída da inferência de gênero utilizando a biblioteca gender_guesser.

03.6. Validações Finais

A etapa final do tratamento de dados teve como principal objetivo confirmar a integridade e a qualidade dos quatro conjuntos de dados tratados: Order, Campaign, CampaignQueue e Customer. Essa validação garantiu que, após todos os processos de limpeza, enriquecimento e padronização, os dados estivessem consistentes, completos e prontos para integração com o banco de dados e utilização em análises e dashboards.

Para essa verificação, foi criada uma função chamada `resumo_base()`, responsável por apresentar um resumo estatístico de cada tabela. A função exibe o nome da base, o número de linhas e colunas, a contagem de registros duplicados e a quantidade de valores nulos por coluna. Essa análise foi essencial para identificar eventuais falhas e assegurar a completude e coerência das informações tratadas.

Os resultados da execução demonstraram que nenhuma das tabelas possui registros duplicados, evidenciando que o processo de normalização foi bem-sucedido. Na tabela Order, observou-se que todos os campos foram devidamente preenchidos, exceto a coluna `scheduledAt`, que apresentou 1.729 valores nulos correspondentes a pedidos não agendados — uma condição esperada para esse tipo de registro. Nenhuma outra coluna apresentou valores ausentes, e todas as variáveis numéricas e textuais estavam devidamente formatadas e padronizadas.

Na tabela Campaign, também não foram detectados registros duplicados, e a única coluna com ausência de valores foi `createdAt`, que apresentou 1.224 registros nulos referentes a campanhas antigas sem data de criação registrada. Esse comportamento é considerado aceitável, uma vez que esses casos foram compensados com a criação da nova coluna `createdAt_filled`, que preenche automaticamente a data de criação com base no valor de `updatedAt`. As demais colunas, incluindo `storeId`, `status_desc` e `_mes`, estavam completas e coerentes com o restante da estrutura.

Já na base CampaignQueue, verificou-se que todos os campos principais, como `campaignId`, `customerId`, `status` e `createdAt`, estavam completos. A única exceção foi a coluna `sendAt`, que apresentou 1.712 valores nulos. Esses nulos representam mensagens ainda não enviadas, sendo, portanto, um comportamento esperado. O relatório de integridade também confirmou que não há duplicações nem inconsistências em colunas de identificação ou relacionamento.

Por fim, na base Customer, observou-se que os campos enrichedAt e enrichedBy apresentaram 496 valores nulos, representando clientes que ainda não haviam passado por processos de enriquecimento de dados. Além disso, o campo gender_inferred apresentou 741 nulos, o que indica casos em que a inferência de gênero, realizada pela biblioteca gender_guesser, não conseguiu determinar o valor com confiança. Apesar dessas ausências, os resultados gerais foram considerados satisfatórios, uma vez que os campos críticos — como id, name, taxId, email, phone e companyId — estavam completos e corretamente padronizados.

Além da análise de nulos e duplicados, foram realizadas múltiplas verificações de integridade referencial entre as bases tratadas, assegurando a coerência dos vínculos entre entidades relacionadas. Primeiramente, verificou-se se todos os campaignId existentes na tabela CampaignQueue estavam devidamente presentes na tabela Campaign, e se todos os customerId da CampaignQueue possuíam correspondência na tabela Customer. Ambas as checagens retornaram zero inconsistências, confirmando que todas as relações entre campanhas, clientes e mensagens foram mantidas corretamente.

Em seguida, a integridade foi validada também entre as demais tabelas: a base Order foi comparada com Customer para garantir que todos os pedidos estejam vinculados a clientes existentes; Order e Customer foram verificados em relação à tabela Estabelecimentos para confirmar que os identificadores de loja (companyId) são válidos; e a tabela Campaign foi checada para assegurar que todos os storeId correspondam a estabelecimentos cadastrados. Em todas essas verificações, o resultado foi igualmente zero registros inválidos, indicando consistência total entre as tabelas.

Com esses resultados, conclui-se que todas as cinco bases — Customer, Order, Campaign, CampaignQueue e Estabelecimentos — encontram-se consistentes, sem registros duplicados, com valores nulos apenas em campos esperados e com todos os relacionamentos entre tabelas devidamente íntegros. Esse cenário reforça a confiabilidade e qualidade dos dados tratados, garantindo que o processo de preparação foi eficaz e que as informações estão totalmente aptas para a fase de integração no banco MySQL e posterior análise no dashboard.

6) Validações finais (nulos, duplicados, integridade)

```
[46] 1 def resumo_base(df, nome):
2     print(f"\n>>> {nome}")
3     print("Linhas/colunas:", df.shape)
4     print("Duplicados:", df.duplicated().sum())
5     print("Nulos por coluna:")
6     print(df.isna().sum())
7
8 resumo_base(order_cl, "Order")
9 resumo_base(campaign_cl, "Campaign")
10 resumo_base(campaign_queue_cl, "CampaignQueue")
11 resumo_base(customer_cl, "Customer")
12
13 # Checagem de integridade
14
15 # Carrega a base de estabelecimentos
16 estab = pd.read_csv("Estabelecimentos.csv", sep=";")
17
18 # CampaignQueue -> Campaign
19 if set(["campaignId"]).issubset(campaign_queue_cl.columns) and "id" in campaign_cl.columns:
20     faltando_camp = (~campaign_queue_cl["campaignId"].isin(campaign_cl["id"])).sum()
21     print("\nCampaignQueue com campaignId inexistente:", faltando_camp)
22
23 # CampaignQueue -> Customer
24 if set(["customerId"]).issubset(campaign_queue_cl.columns) and "id" in customer_cl.columns:
25     faltando_cli = (~campaign_queue_cl["customerId"].isin(customer_cl["id"])).sum()
26     print("CampaignQueue com customerId inexistente:", faltando_cli)
27
28 # Order -> Customer
29 if "customer" in order_cl.columns and "id" in customer_cl.columns:
30     faltando_cli_order = (~order_cl["customer"].isin(customer_cl["id"])).sum()
31     print("\nOrder com customer inexistente:", faltando_cli_order)
32
33 # Order -> Estabelecimentos
34 if "companyId" in order_cl.columns and "establishment_id" in estab.columns:
35     faltando_estab_order = (~order_cl["companyId"].isin(estab["establishment_id"])).sum()
36     print("Order com companyId inexistente em estabelecimentos:", faltando_estab_order)
37
38 # Customer -> Estabelecimentos
39 if "companyId" in customer_cl.columns and "establishment_id" in estab.columns:
40     faltando_estab_cust = (~customer_cl["companyId"].isin(estab["establishment_id"])).sum()
41     print("\nCustomer com companyId inexistente em estabelecimentos:", faltando_estab_cust)
42
43 # Campaign -> Estabelecimentos
44 if "storeId" in campaign_cl.columns and "establishment_id" in estab.columns:
45     faltando_estab_camp = (~campaign_cl["storeId"].isin(estab["establishment_id"])).sum()
46     print("Campaign com storeId inexistente em estabelecimentos:", faltando_estab_camp)
47
```

Figura 13 – Execução do código de verificação de nulos, duplicados e integridade referencial.

```
>>> Order
Linhas/colunas: (3500, 25)
Duplicados: 0
Nulos por coluna:
id              0
companyId        0
containerId      0
createdAt        0
customer          0
displayId         0
engineId          0
engineName        0
engineType        0
extraInfo         0
integrated        0
integrationId     0
isTest            0
orderTiming       0
orderType          0
salesChannel       0
scheduledAt       1729
status             0
preparationTime    0
takeOutTimeInSeconds 0
totalAmount        0
updatedAt          0
version            0
totalAmount_num     0
_mes               0
dtype: int64
```

Figura 14 – Análise de nulos e duplicados na base Order.

```
... >>> Campaign
Linhas/colunas: (2000, 17)
Duplicados: 0
Nulos por coluna:
id              0
segmentId        0
templateId        0
storeId           0
name              0
description        0
badge              0
type               0
status              0
isDefault          0
createdAt         1224
createdBy          0
updatedAt          0
updatedBy          0
status_desc        0
createdAt_filled   0
_mes               0
dtype: int64

>>> CampaignQueue
Linhas/colunas: (5000, 18)
Duplicados: 0
Nulos por coluna:
id              0
jobId            0
campaignId        0
storeId           0
storeInstanceId    0
customerId         0
phoneNumber        0
scheduledAt        0
sendat            1712
status             0
message            0
response            0
createdAt          0
createdBy          0
updatedAt          0
updatedBy          0
status_desc        0
_mes               0
dtype: int64
```

Figura 15 – Análise de nulos e duplicados nas bases Campaign e CampaignQueue.

```

>>> Customer
Linhas/colunas: (1000, 22)
Duplicados: 0
Nulos por coluna:
id              0
name            0
taxId           0
gender          0
dateOfBirth     0
status           0
externalCode    0
isEnriched      0
enrichedAt      496
enrichedBy      496
createdAt       0
createdBy       0
updatedAt        0
updatedBy       0
phone            0
email            0
companyId        0
isEnriched_text  0
status_desc      0
gender_inferred  741
gender_final     0
gender_clean     0
dtype: int64

CampaignQueue com campaignId inexistente: 0
CampaignQueue com customerId inexistente: 0

Order com customer inexistente: 0
Order com companyId inexistente em estabelecimentos: 0

Customer com companyId inexistente em estabelecimentos: 0
Campaign com storeId inexistente em estabelecimentos: 0

```

Figura 16 – Análise de nulos e duplicados na base Customer e validação de integridade.

03.7. Exportação dos dados tratados

Por fim, as bases tratadas foram exportadas novamente em formato CSV, concluindo o processo de preparação.

Foram gerados quatro novos arquivos: Order_clean.csv, Campaign_clean.csv, CampaignQueue_clean.csv e Customer_clean.csv, todos gravados com o separador ";" e sem índice.

Esses arquivos foram posteriormente utilizados em duas etapas fundamentais do projeto:

(1) importação para o banco de dados MySQL através do Table Data Import Wizard, que criou as tabelas definitivas no schema cannoli.

e (2) uso como fonte de dados para os dashboards interativos desenvolvidos em React com Chart.js, permitindo a visualização de KPIs e métricas de forma dinâmica.

Essa etapa marcou o encerramento do ciclo de tratamento e garantiu que os dados estivessem completamente estruturados e prontos para uso em aplicações analíticas.



The screenshot shows a terminal window titled "7) Exportar dados tratados para novos CSVs". On the left, there's a file browser showing a directory structure with files like "sample_data", "Campaign.csv", "CampaignQueue.csv", "CampaignQueue_clean.csv", "Campaign_clean.csv", "Customer.csv", "Customer_clean.csv", "Estabelecimentos.csv", "Order.csv", and "Order_clean.csv". The main pane of the terminal contains Python code:

```
1 order_cl.to_csv("Order_clean.csv", index=False, sep=";")
2 campaign_cl.to_csv("Campaign_clean.csv", index=False, sep=";")
3 campaign_queue_cl.to_csv("CampaignQueue_clean.csv", index=False, sep=";")
4 customer_cl.to_csv("Customer_clean.csv", index=False, sep=";")
5
6 print("Arquivos tratados exportados!")
```

Below the code, a message "Arquivos tratados exportados!" is displayed.

Figura 17 – Exportação final dos arquivos tratados e confirmação da geração dos CSVs limpos.

04. CARGA DAS BASES TRATADAS NO MYSQL

Após a finalização do processo de tratamento, padronização e enriquecimento, os dados foram preparados para serem integrados em um ambiente de banco de dados relacional, de forma a permitir análises mais rápidas, consultas otimizadas e conexão direta com a aplicação Cannoli Intelligence Dashboard. Para isso, foi utilizada a ferramenta Table Data Import Wizard, disponível no MySQL Workbench, que possibilita a importação direta dos arquivos CSV tratados para o banco de dados, automatizando a criação das tabelas e a inserção dos registros.

Os arquivos Order_clean.csv, Customer_clean.csv, Campaign_clean.csv, CampaignQueue_clean.csv e Estabelecimentos.csv foram carregados para o schema cannoli, resultando na criação de cinco tabelas principais correspondentes às bases tratadas. Cada tabela foi validada para assegurar a correspondência entre os campos originais e os tipos de dados atribuídos no MySQL, como VARCHAR, INT, DECIMAL e DATE. Esse processo garantiu que todos os registros mantivessem integridade e compatibilidade com as etapas posteriores de análise e visualização, além de preservar a estrutura lógica aplicada durante o tratamento dos dados.

Durante a carga das tabelas tratadas, também foram configuradas duas novas estruturas complementares, essenciais para a operação do sistema e para o uso de inteligência artificial. A primeira é a tabela campaign_ai_sugestoes, criada para armazenar os resultados gerados pelo modelo de aprendizado de máquina desenvolvido com o algoritmo RandomForestClassifier. Essa tabela contém os campos campaignId, storeId, status_previsto, confianca, grupo, modelo_versao e gerado_em, permitindo registrar as previsões de desempenho das campanhas. Por meio dela, o sistema pode exibir sugestões automáticas de otimização, como ajustar, pausar ou reforçar campanhas de marketing conforme o comportamento previsto. Essa integração entre dados tratados e resultados preditivos amplia as possibilidades analíticas do projeto, unindo análise descritiva e inteligência artificial em um único ambiente de dados.

A segunda tabela adicional criada foi a usuarios, responsável pelo gerenciamento de acessos ao dashboard e pela autenticação dos diferentes perfis de usuários. Cada registro nessa tabela contém o identificador do usuário, nome, e-mail, senha (armazenada de forma criptografada), perfil de acesso e, quando aplicável, o identificador do estabelecimento vinculado. O campo perfil define o nível de permissão dentro do sistema, diferenciando administradores (ADMIN) — que podem visualizar todas as informações — dos usuários de estabelecimentos (ESTABELECIMENTO), que têm acesso apenas aos dados da própria loja. Essa estrutura garante controle, segurança e privacidade no acesso às informações,

além de permitir que a autenticação seja diretamente integrada à aplicação web desenvolvida em React.

Ao término da importação, o banco de dados cannoli consolidou um total de sete tabelas: order, customer, campaign, campaign_queue, estabelecimentos, campaign_ai_sugestoes e usuarios. Essa estrutura unificada reflete toda a arquitetura lógica do projeto, integrando dados operacionais, preditivos e administrativos em um único ambiente relacional. O processo de importação assegurou integridade referencial entre as tabelas, consistência dos dados e compatibilidade total com o sistema React e os futuros módulos analíticos.

Com isso, o ambiente de dados foi preparado para servir como base do ecossistema Cannoli Intelligence, permitindo o consumo das informações tanto por consultas SQL quanto por aplicações externas. O formato relacional adotado garante escalabilidade e flexibilidade, possibilitando futuras expansões do sistema com novas tabelas, previsões ou integrações com modelos de inteligência artificial. Assim, a carga das bases tratadas no MySQL representa o encerramento da etapa de preparação e a transição para a fase analítica e de visualização dos resultados.

Tabela	Ação	Linhas	Tipo	Colação	Tamanho	Sobrecarga
campaign	Visualizar Estrutura Procurar Inserir Limpar Eliminar	2.000	MyISAM	utf8mb4_0900_ai_ci	449.9 KB	-
campaign_ai_sugestoes	Visualizar Estrutura Procurar Inserir Limpar Eliminar	4.000	MyISAM	utf8mb4_0900_ai_ci	339.2 KB	-
campaign_queue	Visualizar Estrutura Procurar Inserir Limpar Eliminar	5.000	MyISAM	utf8mb4_0900_ai_ci	1.4 MB	-
customer	Visualizar Estrutura Procurar Inserir Limpar Eliminar	1.000	MyISAM	utf8mb4_0900_ai_ci	233.7 KB	-
estabelecimentos	Visualizar Estrutura Procurar Inserir Limpar Eliminar	12	InnoDB	utf8mb4_0900_ai_ci	16.0 KB	-
order	Visualizar Estrutura Procurar Inserir Limpar Eliminar	3.500	MyISAM	utf8mb4_0900_ai_ci	915.0 KB	-
usuarios	Visualizar Estrutura Procurar Inserir Limpar Eliminar	13	MyISAM	utf8mb4_0900_ai_ci	10.7 KB	-
7 tabelas	Soma	15.525	MyISAM	utf8mb4_0900_ai_ci	3.3 MB	0 Bytes

Figura 18 – Estrutura final das tabelas no banco de dados cannoli, mostrando a integração das bases tratadas e das tabelas adicionais de IA e usuários.

05. CONCLUSÃO

Portanto, com a finalização desta etapa, o projeto Cannoli Intelligence atingiu um marco essencial na construção de sua base de dados. As informações, antes dispersas e inconsistentes, foram transformadas em um conjunto coeso, limpo e padronizado, pronto para sustentar análises de alto nível. O processo de tratamento e enriquecimento automatizado, aliado à integração das tabelas no ambiente relacional do MySQL, estabeleceu uma estrutura sólida e confiável para o armazenamento e processamento dos dados.

Esse novo modelo de dados permite a geração de indicadores de desempenho (KPIs) e a construção de dashboards interativos, que poderão ser utilizados tanto por administradores quanto por estabelecimentos parceiros para acompanhar métricas em tempo real. Além disso, a padronização e o controle de integridade garantem consistência entre as diferentes fontes, tornando as análises mais precisas e as decisões mais assertivas.

Assim, a conclusão desta fase consolida o ambiente analítico do Cannoli Intelligence, transformando dados brutos em informação estratégica. Essa estrutura de dados, agora robusta e escalável, servirá como base para as próximas etapas do projeto — incluindo o desenvolvimento da camada de visualização, os módulos de inteligência artificial e as funcionalidades de recomendação automatizada — assegurando qualidade, confiabilidade e valor agregado às análises e à tomada de decisão.